Busca de Documentos com Similaridade por Cosseno

Aplicação 1 — Obtenção de Informações: Revista

udesc_background

André Ghisleni Raimann

Álgebra Linear

2026

Da coleção de documentos à matriz

Representação

$$A \in \mathbb{R}^{10\times 8}$$

- As dez linhas representam palavras-chave.
- As oito colunas representam módulos (documentos).
- A entrada a_{ij} conta as ocorrências da palavra i no módulo j.

Recorte da matriz original — módulos M1 a M4:

Palavra	M1	M2	M3	M4
determinantes	0	6	3	0

A linguagem complica a busca

Polissemia: uma palavra pode ter sentidos diferentes.

Sinonímia: o mesmo sentido pode aparecer em palavras distintas.

O exemplo começa com contagem de frequências; essa etapa, sozinha, não resolve esses dois casos.

A consulta também é um vetor

A busca usa três palavras-chave: **ortogonalidade**, **espaços** e **vetor**.

Vetor unitário de busca

$$\boldsymbol{x} = \frac{1}{\sqrt{3}}(0,0,0,0,0,1,1,0,0,1)^{\mathsf{T}}, \qquad \|\boldsymbol{x}\| = 1.$$

- As posições diferentes de zero correspondem exatamente aos três termos da consulta.
- O fator $1/\sqrt{3}$ dá o mesmo peso a cada termo e deixa o vetor com comprimento 1.

Normalizar e comparar direções

Cada coluna de frequências $\boldsymbol{a}_j$ é transformada em um vetor unitário:

$$\boldsymbol{q}_j = \frac{\boldsymbol{a}_j}{\|\boldsymbol{a}_j\|}.$$

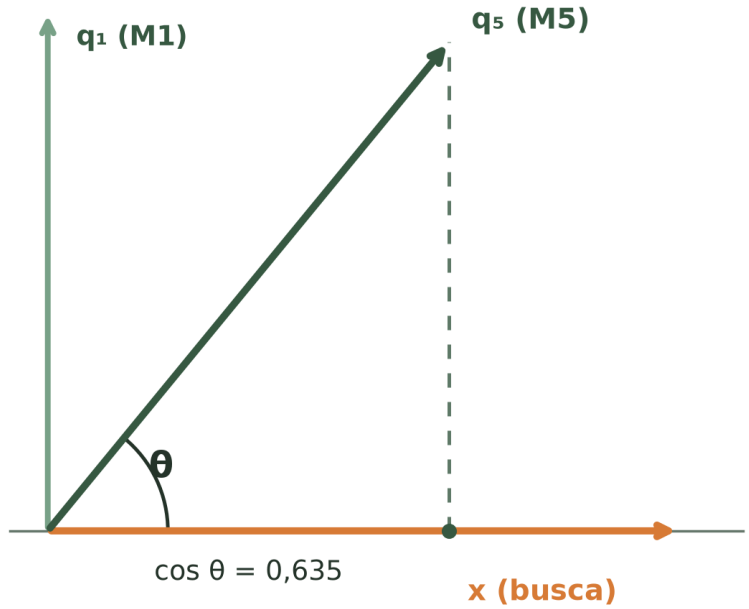
O escore do módulo j é

$$y_j = \boldsymbol{q}_j^{\mathsf{T}} \boldsymbol{x} = \cos\theta_j.$$

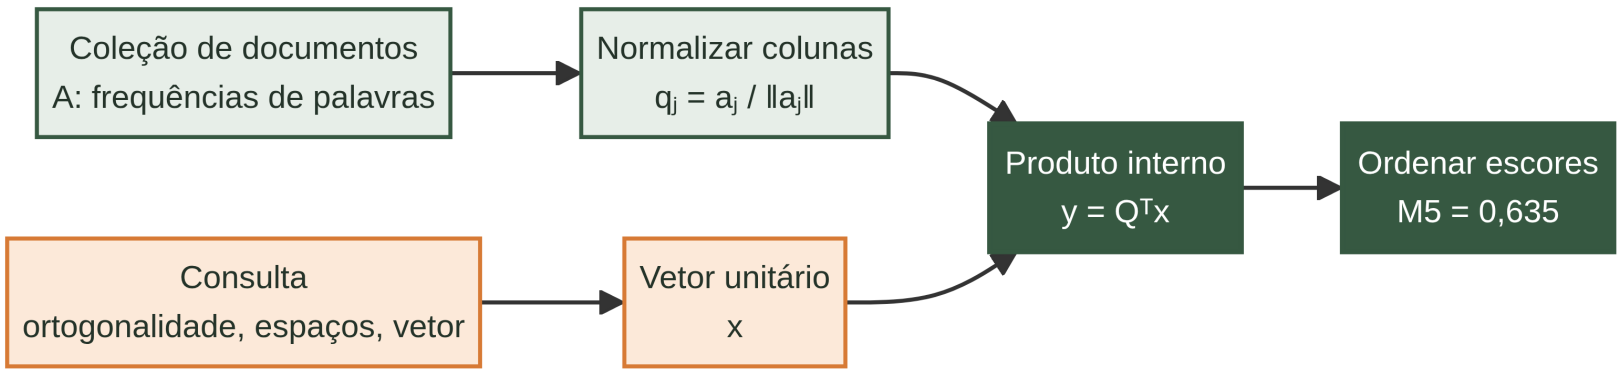
- Direções próximas produzem cosseno maior.
- Vetores ortogonais produzem escore zero.

Esquema 2D; os vetores reais têm 10 dimensões.

udesc_backg



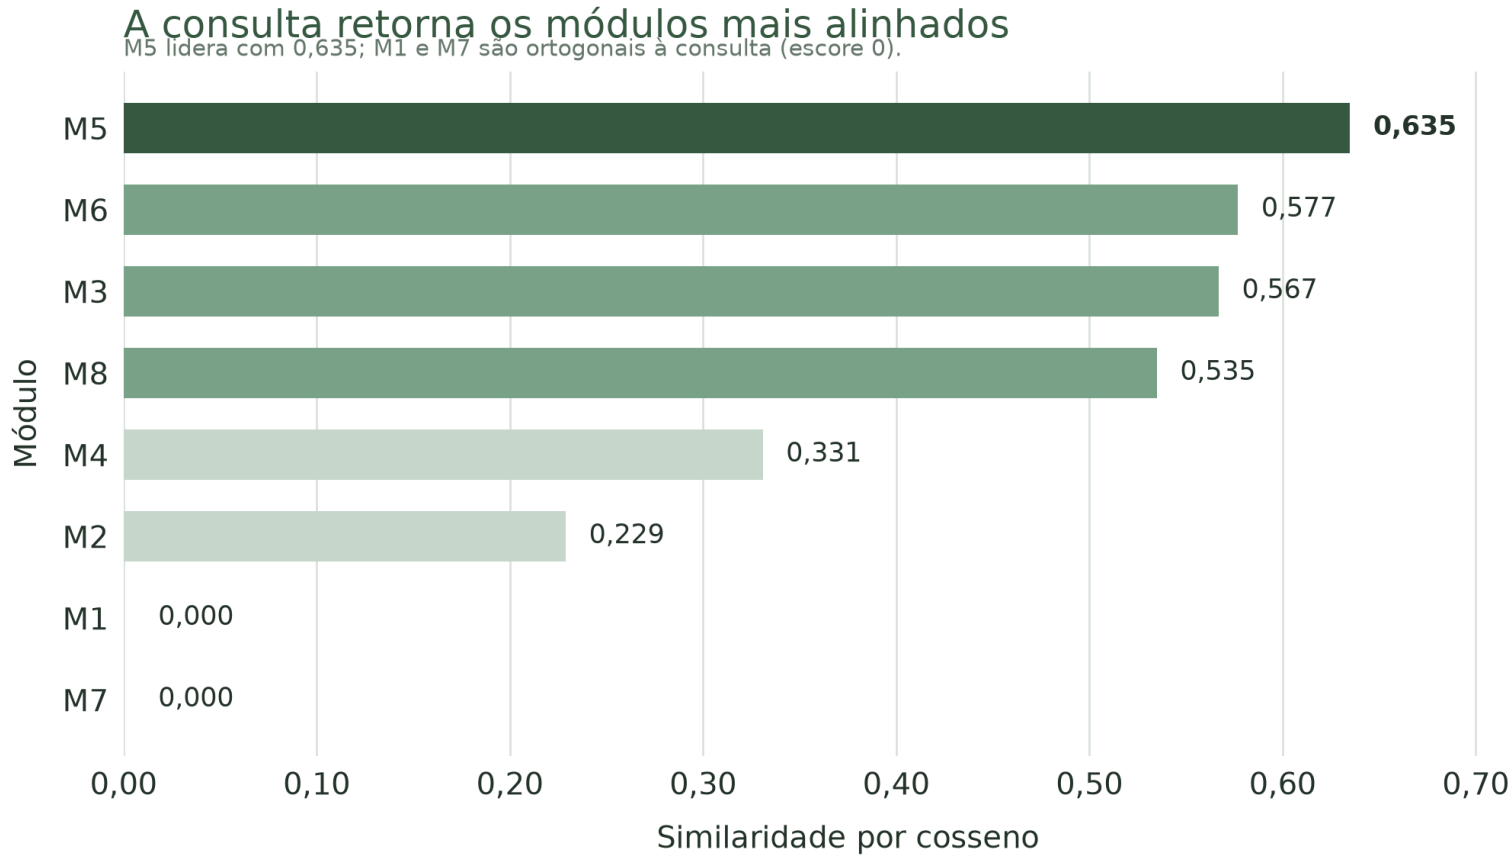
O processo da busca



Em uma linha

Frequências $\longrightarrow$ normalização $\longrightarrow$ produto interno $\longrightarrow$ ranking.

Os módulos mais próximos da consulta



A consulta é mais alinhada com M5; M6, M3 e M8 vêm logo depois.

Por que o módulo M5 lidera?

No vetor normalizado de M5, as componentes de *ortogonalidade*, *espaços* e *vetor* são 0,400, 0,300 e 0,400.

Produto interno com a consulta

$$\boldsymbol{q}_5^{\mathsf{T}}\boldsymbol{x} = \frac{0{,}400 + 0{,}300 + 0{,}400}{\sqrt{3}} \approx 0{,}635.$$

Interpretação

0,635 é o maior escore entre os oito módulos. É uma medida geométrica para ordenar documentos, não uma porcentagem de relevância.

O alcance e os limites do exemplo

- A matriz de frequências permite ordenar os documentos pela direção dos vetores.
- M1 e M7 não contêm nenhum dos três termos buscados; por isso, seus vetores são ortogonais à consulta e recebem escore 0.
- A contagem literal não reconhece sinônimos nem distingue automaticamente sentidos diferentes de uma palavra.

Próximo passo citado por Leon

A indexação semântica latente (ISL), baseada em decomposição por valores singulares, pode ajudar a lidar com polissemia e sinonímia.

Fonte: Steven J. Leon, *Álgebra Linear com Aplicações*, cap. 5, Aplicação 1, pp. 191–193 (PDF, pp. 197–199).