Cola para apresentar

Busca de documentos com similaridade por cosseno

Base: Steven J. Leon, *Álgebra Linear com Aplicações*, Aplicação 1, pp. 191–193 (PDF pp. 197–199).

Mensagem central. A busca e cada documento são representados por vetores. O cosseno do ângulo entre eles dá um escore para ordenar quais documentos mais se parecem com a consulta.

Roteiro dos slides

1. Capa — apresente a pergunta.
Como encontrar os módulos que melhor correspondem a uma lista de palavras? A aplicação do livro transforma a busca em um problema geométrico de álgebra linear.

2. Documentos como matriz.
Explique que as linhas são 10 palavras-chave e as colunas são 8 módulos. Cada entrada conta a frequência de uma palavra num módulo. A matriz é $A \in \mathbb{R}^{10\times 8}$.
Lembrete: não é uma matriz de similaridades ainda; ela contém frequências.
Transição: *agora representamos a pergunta da pessoa também como um vetor.*

3. Vetor de busca.
A consulta usa *ortogonalidade*, *espaços* e *vetor*. Só as posições dessas palavras ficam diferentes de zero, com peso $1/\sqrt{3} \approx 0{,}577$. Assim, $\|x\| = 1$ e os três termos recebem o mesmo peso.
Lembrete: na ordem da tabela do livro, os valores não nulos estão nas posições 6, 7 e 10.

4. Normalização e cosseno.
Cada vetor-documento a_j é normalizado: $q_j = a_j/\|a_j\|$. O escore é $y_j = q_j^{\mathsf{T}} x = \cos\theta_j$. Vetores mais alinhados dão escores maiores; vetores ortogonais dão zero.
Lembrete: normalizar reduz o efeito do tamanho total do vetor; comparar cossenos é comparar direções. A figura 2D é esquemática: os vetores reais têm 10 componentes.

5. Fluxo.
Recapitule em voz alta: matriz de frequências → normalização das colunas → produto interno com a consulta → ranking. A operação conjunta é $y = Q^{\mathsf{T}} x$.

6. Ranking.
Leia apenas os principais resultados: M5 fica em primeiro com 0,635; depois vêm M6 com 0,577, M3 com 0,567 e M8 com 0,535. M1 e M7 recebem zero porque não têm nenhum dos três termos da consulta.

Conta, interpretação e perguntas

Continuação do roteiro de apoio · Aplicação 1

Termine o percurso dos slides

7. Por que M5 lidera?
Mostre as três componentes de q_5 que correspondem à consulta: 0,400; 0,300; 0,400. Calcule o produto interno:

$$q_5^{\mathsf{T}} x = 0{,}400(0{,}577) + 0{,}300(0{,}577) + 0{,}400(0{,}577) = \frac{0{,}400 + 0{,}300 + 0{,}400}{\sqrt{3}} \approx 0{,}635.$$

Lembrete: arredondamentos explicam pequenas diferenças no último decimal.

8. Conclusão e limites.
O método ordena documentos usando as frequências e o ângulo. Mas uma busca literal não entende automaticamente que duas palavras são sinônimas nem distingue sentidos diferentes da mesma palavra. O texto aponta a indexação semântica latente (ISL), baseada em decomposição por valores singulares, como técnica mais avançada.

Números para consultar rapidamente

Módulo	Escore	Módulo	Escore
M5	0,635	M4	0,331
M6	0,577	M2	0,229
M3	0,567	M1	0,000
M8	0,535	M7	0,000

Perguntas prováveis

Por que normalizar os documentos? Para pôr os vetores numa escala comum e fazer a comparação focar na direção, não apenas no comprimento bruto do vetor de frequências.

0,635 significa 63,5% de relevância? Não. É o cosseno do ângulo entre os vetores normalizados e serve como escore de ordenação. Não é probabilidade nem porcentagem.

Por que M1 e M7 têm escore zero? Neste exemplo, eles não contêm nenhuma palavra da consulta. Logo, o produto interno com o vetor de busca é zero.

O cosseno resolve sinônimos e polissemia? Não nesta representação simples por contagem literal. Esse é um dos motivos para técnicas semânticas posteriores, como a ISL/SVD.

Não esqueça

- Diga que o vetor da busca também é unitário.
- Diferencie frequência (entrada da matriz) de similaridade (produto interno após normalização).
- Explique o que os zeros significam neste exemplo, sem generalizar para toda busca.
- Não chame o escore de percentual ou probabilidade.
- Feche com a limitação semântica e a conexão com ISL/SVD.

Frase de fechamento: "A geometria transforma a busca por palavras em comparação de direções: quanto mais alinhado o documento com a consulta, maior seu cosseno e melhor sua posição no ranking."